



最优化理论

第2讲 最优化理论的数学基础(1)

辽宁大学 信息学院



2023年9月25日星期一

遼寧大學

最优化理论的数学基础


-  函数梯度
-  多元函数的泰勒展开式
-  二次函数
-  无约束优化问题的极值条件
-  约束优化问题的极值条件
-  优化设计方法的基本思想与迭代终止准则

1. 函数的梯度

方向导数

 对于一个多元函数，它的**偏导数**代表了沿着某个坐标方向的函数变化率。

方向导数是沿着给定方向的函数变化率



1. 函数的梯度


🖥️ 方向导数

🏠 假设维度 $n=2$

$$\|\Delta S\| = \sqrt{(\Delta x_1)^2 + (\Delta x_2)^2}$$

$$\frac{\Delta f(X)}{\|\Delta S\|} = \frac{f(x_1 + \Delta x_1, x_2 + \Delta x_2) - f(x_1, x_2)}{\|\Delta S\|}$$


$$\frac{\partial f(X)}{\partial S} = \lim_{\|\Delta S\| \rightarrow 0} \frac{\Delta f(X)}{\|\Delta S\|} = \lim_{\|\Delta S\| \rightarrow 0} \frac{f(x_1 + \Delta x_1, x_2 + \Delta x_2) - f(x_1, x_2)}{\|\Delta S\|}$$



$f(X)$ 对方向 s 的方向导数

方向导数的推导公式

$$\begin{aligned}
 \frac{\partial f(X)}{\partial S} &= \lim_{\|\Delta S\| \rightarrow 0} \frac{\Delta f(X)}{\|\Delta S\|} = \lim_{\|\Delta S\| \rightarrow 0} \frac{f(x_1 + \Delta x_1, x_2 + \Delta x_2) - f(x_1, x_2)}{\|\Delta S\|} \\
 &= \lim_{\|\Delta S\| \rightarrow 0} \left\{ \frac{f(x_1 + \Delta x_1, x_2 + \Delta x_2) - f(x_1, x_2) + f(x_1, x_2 + \Delta x_2) - f(x_1, x_2 + \Delta x_2)}{\|\Delta S\|} \cdot \frac{\Delta x_1}{\Delta x_1} \cdot \frac{\Delta x_2}{\Delta x_2} \right\} \\
 &= \lim_{\|\Delta S\| \rightarrow 0} \left\{ \frac{f(x_1 + \Delta x_1, x_2 + \Delta x_2) - f(x_1, x_2 + \Delta x_2)}{\Delta x_1} \cdot \frac{\Delta x_1}{\|\Delta S\|} \right. \\
 &\quad \left. + \frac{f(x_1, x_2 + \Delta x_2) - f(x_1, x_2)}{\Delta x_2} \cdot \frac{\Delta x_2}{\|\Delta S\|} \right\}
 \end{aligned}$$



$$\frac{\partial f(X)}{\partial S} = \frac{\partial f(X)}{\partial x_1} \cos(\alpha_1) + \frac{\partial f(X)}{\partial x_2} \cos(\alpha_2)$$

方向导数的推导公式

$$\frac{\partial f(X)}{\partial S} = \frac{\partial f(X)}{\partial x_1} \cos(\alpha_1) + \frac{\partial f(X)}{\partial x_2} \cos(\alpha_2)$$


$$\cos(\alpha_1) = \frac{\Delta x_1}{\|\Delta S\|}, \cos(\alpha_2) = \frac{\Delta x_2}{\|\Delta S\|}$$

$$s.t. \quad \cos^2(\alpha_1) + \cos^2(\alpha_2) = 1$$

$$\text{当 } \alpha_1 = 0 \text{ 时, } \frac{\partial f(X)}{\partial S} = \frac{\partial f(X)}{\partial x_1}$$

$$\text{当 } \alpha_2 = 0 \text{ 时, } \frac{\partial f(X)}{\partial S} = \frac{\partial f(X)}{\partial x_2}$$

方向余弦



偏导数是方向导数的特例

1. 函数的梯度

方向导数

推广到n维的多元函数

$$\frac{\partial f(X)}{\partial S} = \sum_{i=1}^n \frac{\partial f(X)}{\partial x_i} \cos(\alpha_i)$$

$$s.t. \quad \sum_{i=1}^n \cos^2(\alpha_i) = 1$$

方向余弦

1. 函数的梯度



例1（P14例2-1）：方向导数计算

 求函数 $f(X) = \frac{\pi}{4}x_1^2x_2$ 分别沿以下两个方向

$$S_1 = \begin{cases} \alpha_1 = \frac{\pi}{4} \\ \alpha_2 = \frac{\pi}{4} \end{cases} \quad S_2 = \begin{cases} \alpha_1 = \frac{\pi}{3} \\ \alpha_2 = \frac{\pi}{6} \end{cases}$$

在点 $X^{(0)} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 处的方向导数。

例1：解

$$\therefore \frac{\partial f(X)}{\partial S} = \frac{\partial f(X)}{\partial x_1} \cos(\alpha_1) + \frac{\partial f(X)}{\partial x_2} \cos(\alpha_2)$$

$$\frac{\partial f(X)}{\partial x_1} = \frac{\pi}{4} \cdot 2x_1x_2 = \frac{\pi}{2} x_1x_2 \Big|_{X=(1,1)} = \frac{\pi}{2}$$

$$\frac{\partial f(X)}{\partial x_2} = \frac{\pi}{4} x_1^2 \Big|_{X=(1,1)} = \frac{\pi}{4}$$

$$\cos\left(\frac{\pi}{4}\right) = \frac{\sqrt{2}}{2}$$

$$\cos\left(\frac{\pi}{3}\right) = \frac{1}{2}, \quad \cos\left(\frac{\pi}{6}\right) = \frac{\sqrt{3}}{2}$$

$$\therefore \frac{\partial f(X)}{\partial S_1} = \frac{\pi}{2} \cdot \frac{\sqrt{2}}{2} + \frac{\pi}{4} \cdot \frac{\sqrt{2}}{2} = \frac{3\sqrt{2}}{8} \pi$$

$$\frac{\partial f(X)}{\partial S_2} = \frac{\pi}{2} \cdot \frac{1}{2} + \frac{\pi}{4} \cdot \frac{\sqrt{3}}{2} = \frac{2 + \sqrt{3}}{8} \pi$$

相同点，不同的
方向变化率是不
同的


1. 函数的梯度

知识回顾：向量及其基本运算

向量的定义

 **向量**：既有**大小**，又有**方向**的量，也称为矢量。

- 通常用 $\vec{a}$ 的样式表示（本课程为了书写方便，用大写的字母表示一个向量）
- 二维坐标系中，一个向量代表从原点出发具有方向的一条线，向量 $X=(x1,x2)$ ，其中 $(x1,x2)$ 是向量的终点。




1. 函数的梯度

知识回顾：向量及其基本运算

向量的定义

 **向量的模**：对于向量 X ，用 $|X|$ 或 $\|X\|$ 表示**向量的长度**，也称为向量的模。

$$\text{对于 } X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \|X\| = \sqrt{x_1^2 + x_2^2}$$



1. 函数的梯度


知识回顾：向量及其基本运算

向量点积运算

$$X = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad Y = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}$$

$$X^T \cdot Y = [x_1, x_2] \cdot \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = x_1 y_1 + x_2 y_2$$

$$X^T \cdot Y = \|X\| \cdot \|Y\| \cos \theta$$




1. 函数的梯度

函数梯度的定义

 当多元函数维度 $n=2$ 时

$$\begin{aligned}\frac{\partial f(X)}{\partial S} &= \frac{\partial f(X)}{\partial x_1} \cos(\alpha_1) + \frac{\partial f(X)}{\partial x_2} \cos(\alpha_2) \\ &= \left[\frac{\partial f(X)}{\partial x_1}, \frac{\partial f(X)}{\partial x_2} \right] \cdot \begin{bmatrix} \cos(\alpha_1) \\ \cos(\alpha_2) \end{bmatrix} \\ &= \begin{bmatrix} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \end{bmatrix}^T \cdot S\end{aligned}$$




函数的梯度公式推导

$$\frac{\partial f(X)}{\partial S} = \begin{bmatrix} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \end{bmatrix}^T \cdot S = \left\| \begin{bmatrix} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \end{bmatrix} \right\| \cdot \|S\| \cos \theta$$

方向向量 $\begin{bmatrix} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \end{bmatrix}$

函数的梯度

$$\nabla f(X) = \begin{bmatrix} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \end{bmatrix}$$




函数的梯度公式推导

$$\begin{aligned}\frac{\partial f(X)}{\partial S} &= \nabla f^T(X) \cdot S \\ &= \|\nabla f(X)\| \cdot \|S\| \cos \theta\end{aligned}$$

$$S = \begin{bmatrix} \cos(\alpha_1) \\ \cos(\alpha_2) \end{bmatrix}, \quad \|S\| = 1$$

$$\because -1 \leq \cos \theta \leq 1$$

$$\therefore \cos \theta = 1 \text{ 时, } \frac{\partial f(X)}{\partial S} \text{ 的值最大}$$



1. 函数的梯度

函数梯度的定义

 函数梯度 (n=2) :

$$\|\nabla f(X)\| = \sqrt{\left(\frac{\partial f(X)}{\partial x_1}\right)^2 + \left(\frac{\partial f(X)}{\partial x_2}\right)^2}$$

☞ 把取得函数方向导数最大值的向量 $\nabla f(X) = \begin{bmatrix} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \end{bmatrix}$ 称

为函数 $f(X)$ 在点 X 处的梯度

- 用符号 ∇ (grand) 表示梯度
- 一个函数的梯度是固定的，与 S 方向无关
- $\nabla f(X)$ 有方向和大小

1. 函数的梯度

函数梯度的定义

 函数梯度（n维函数）：

$$\nabla f(X) = \begin{bmatrix} \frac{\partial f(X)}{\partial x_1} \\ \dots \\ \frac{\partial f(X)}{\partial x_n} \end{bmatrix}$$

$$\|\nabla f(X)\| = \sqrt{\sum_{i=1}^n \left(\frac{\partial f(X)}{\partial x_i} \right)^2}$$

1. 函数的梯度

函数梯度的性质


 梯度 $\nabla f(X)$ 与过点 X 的等值线正交（垂直）

 函数 $f(X)$ 在点 X 附件的最速上升方向是 $\nabla f(X)$ ，最速下降方向是 $-\nabla f(X)$

 不同点的函数梯度是不同的

 函数的梯度只能反映某一点的局部特征

沿着等值线方向的函数变化率为0，也就是说该方向与梯度方向的夹角为90度（余弦值为0）



1. 函数的梯度

函数梯度的性质


 对于任意给定方向 S ，则根据梯度 $\nabla f(X)$ 可以得到如下结论：

1. $\nabla f^T(X) \cdot S > 0$, 则 S 是上升方向
2. $\nabla f^T(X) \cdot S < 0$, 则 S 是下降方向

$$\because \nabla f^T(x) \cdot S = \|\nabla f(x)\| \cdot \|S\| \cos \theta$$

$$\therefore \nabla f^T(x) \cdot S > 0 \Rightarrow \cos \theta > 0 \Rightarrow 0 \leq \theta < \frac{\pi}{2}$$

$$\nabla f^T(x) \cdot S < 0 \Rightarrow \cos \theta < 0 \Rightarrow \frac{\pi}{2} < \theta \leq \pi$$



1. 函数的梯度

例2（P15例2-2）：梯度的计算


 求函数 $f(X) = 3x_1^2 - 2x_1x_2 + 3x_2^2 - 2x_2x_3 + 3x_3^2 - 2x_1x_3$

在点 $X^{(1)} = [1, 2, 3]^T$ 处的梯度及梯度的模

例2：解

$$f(X) = 3x_1^2 - 2x_1x_2 + 3x_2^2 - 2x_2x_3 + 3x_3^2 - 2x_1x_3$$

$$\nabla f(X) = \begin{bmatrix} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \\ \frac{\partial f(X)}{\partial x_3} \end{bmatrix} = \begin{bmatrix} 6x_1 - 2x_2 - 2x_3 \\ -2x_1 + 6x_2 - 2x_3 \\ -2x_2 + 6x_3 - 2x_1 \end{bmatrix}$$

帶入 $X^{(1)} = [1, 2, 3]^T$  $\nabla f(X^{(1)}) = [-4, 4, 12]^T$
 $\|\nabla f(X^{(1)})\| = 4\sqrt{11}$

2. 多元函数的泰勒(Taylor)展开式

 知识点回顾：一元函数的泰勒展开

 一元函数 $f(x)$ 在点 $x^{(k)}$ 存在1到n阶导数，则 $f(x)$ 在点 $x^{(k)}$ 的泰勒展开式定义为：

$$f(x) = f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) + \frac{1}{2!} f''(x^{(k)})(x - x^{(k)})^2 \\ + \frac{1}{3!} f'''(x^{(k)})(x - x^{(k)})^3 + \cdots + \frac{1}{n!} f^n(x^{(k)})(x - x^{(k)})^n + R^n$$

R^n 是余项

2. 多元函数的泰勒(Taylor)展开式

 知识点回顾：一元函数的泰勒展开

 为了减少计算量，通常可以取前几项的近似结果，例如扩展到2阶：

$$f(x) \approx f(x^{(k)}) + f'(x^{(k)})(x - x^{(k)}) + \frac{1}{2}f''(x^{(k)})(x - x^{(k)})^2$$

2. 多元函数的泰勒(Taylor)展开式

多元函数的泰勒展开式

-  工程设计中，复杂的目标函数需要进行必要的化简，因此多元函数的泰勒展开式具有广泛应用。
-  工程应用中，一般的泰勒展开式只取前几项（例如前3项（2阶导数））。
-  多元函数通过计算梯度来实现泰勒展开。

2. 多元函数的泰勒(Taylor)展开式

多元函数的泰勒展开式

 多元函数 $f(X)$ 在点 $X^{(k)}$ 处的泰勒展开式定义为（只取前3项）：

$$f(X) \approx f(X^{(k)}) + [\nabla f(X^{(k)})]^T (X - X^{(k)}) + \frac{1}{2} [X - X^{(k)}]^T H(X^{(k)}) (X - X^{(k)})$$

$H(X^{(k)})$ 相当于多元函数在 $X^{(k)}$ 点的二阶梯度（对于一元函数的二阶导数），称为海塞（Hessian）矩阵

海塞 (Hessian) 矩阵

 多元函数 $f(X)$ 在点 X 处所有二阶偏导数组成的矩阵

$$H(X) = \begin{bmatrix} \frac{\partial^2 f(X)}{\partial x_1^2} & \frac{\partial^2 f(X)}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(X)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(X)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(X)}{\partial x_2^2} & \cdots & \frac{\partial^2 f(X)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(X)}{\partial x_n \partial x_1} & \frac{\partial^2 f(X)}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(X)}{\partial x_n^2} \end{bmatrix}$$

海塞 (Hessian)
矩阵是一个 $n \times n$
阶的对称矩阵

$$\therefore \frac{\partial^2 f(X)}{\partial x_i \partial x_j} = \frac{\partial^2 f(X)}{\partial x_j \partial x_i}$$

2. 多元函数的泰勒(Taylor)展开式

例3 (P17例2-4) : 泰勒展开式

 将函数 $f(X) = x_1^3 - x_2^3 + 3x_1^2 + 3x_2^2 - 9x_1$

在点 $X^{(0)} = [1, 1]^T$ 处分别简化成线性函数和二次函数。

$$f(X) \approx \boxed{f(X^{(k)})} + \boxed{\left[\nabla f(X^{(k)})\right]^T} (X - X^{(k)}) + \frac{1}{2} \left[X - X^{(k)} \right]^T \boxed{H(X^{(k)})} (X - X^{(k)})$$

函数值

梯度

海塞矩阵

例3：解

$$f(X) = x_1^3 - x_2^3 + 3x_1^2 + 3x_2^2 - 9x_1$$

1. 求在点 $X^{(0)} = [1, 1]^T$ 处的函数值

$$f(X^{(0)}) = 1^3 - 1^3 + 3 + 3 - 9 = -3$$

2. 求在点 $X^{(0)} = [1, 1]^T$ 处的梯度

$$\nabla f(X^{(0)}) = \left[\begin{array}{c} \frac{\partial f(X)}{\partial x_1} \\ \frac{\partial f(X)}{\partial x_2} \end{array} \right] \bigg|_{X=(1,1)} = \left[\begin{array}{c} 3x_1^2 + 6x_1 - 9 \\ -3x_2^2 + 6x_2 \end{array} \right] \bigg|_{X=(1,1)} = \left[\begin{array}{c} 0 \\ 3 \end{array} \right]$$

例3：解

$$f(X) = x_1^3 - x_2^3 + 3x_1^2 + 3x_2^2 - 9x_1$$

3.求在点 $X^{(0)} = [1, 1]^T$ 处的海塞矩阵

$$H(X^{(0)}) = \begin{bmatrix} \frac{\partial^2 f(X)}{\partial x_1^2} & \frac{\partial^2 f(X)}{\partial x_1 x_2} \\ \frac{\partial^2 f(X)}{\partial x_2 x_1} & \frac{\partial^2 f(X)}{\partial x_2^2} \end{bmatrix} \bigg|_{X=[1,1]^T} = \begin{bmatrix} \frac{3x_1^2 + 6x_1 - 9}{\partial x_1} & \frac{3x_1^2 + 6x_1 - 9}{\partial x_2} \\ \frac{-3x_2^2 + 6x_2}{\partial x_1} & \frac{-3x_2^2 + 6x_2}{\partial x_2} \end{bmatrix} \bigg|_{X=[1,1]^T}$$

$$= \begin{bmatrix} 6x_1 + 6 & 0 \\ 0 & -6x_2 + 6 \end{bmatrix} \bigg|_{X=[1,1]^T} = \begin{bmatrix} 12 & 0 \\ 0 & 0 \end{bmatrix}$$

例3：解

$$f(X) = x_1^3 - x_2^3 + 3x_1^2 + 3x_2^2 - 9x_1$$

$$f(X^{(0)}) = -3, \quad \nabla f(X^{(0)}) = \begin{bmatrix} 0 \\ 3 \end{bmatrix}, \quad H(X^{(0)}) = \begin{bmatrix} 12 & 0 \\ 0 & 0 \end{bmatrix}$$

4. 化简成线性函数（仅保留一次项）

$$f(X) \approx f(X^{(0)}) + [\nabla f(X^{(0)})]^T (X - X^{(0)})$$

$$\approx -3 + [0, 3] \cdot \begin{bmatrix} x_1 - 1 \\ x_2 - 1 \end{bmatrix}$$

$$\approx -3 + 0(x_1 - 1) + 3(x_2 - 1) \approx 3x_2 - 6$$

例3：解

$$f(X) = x_1^3 - x_2^3 + 3x_1^2 + 3x_2^2 - 9x_1$$

$$f(X^{(0)}) = -3, \quad \nabla f(X^{(0)}) = \begin{bmatrix} 0 \\ 3 \end{bmatrix}, \quad H(X^{(0)}) = \begin{bmatrix} 12 & 0 \\ 0 & 0 \end{bmatrix}$$

5. 化简成二次函数（保留到二次项）

$$\begin{aligned} f(X) &\approx f(X^{(0)}) + [\nabla f(X^{(0)})]^T (X - X^{(0)}) + \frac{1}{2} [X - X^{(0)}]^T H(X^{(0)}) (X - X^{(0)}) \\ &\approx 3x_2 - 6 + \frac{1}{2} [x_1 - 1, x_2 - 1] \begin{bmatrix} 12 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 - 1 \\ x_2 - 1 \end{bmatrix} \\ &\approx 3x_2 - 6 + [6(x_1 - 1), 0] \begin{bmatrix} x_1 - 1 \\ x_2 - 1 \end{bmatrix} \approx 6x_1^2 - 12x_1 + 3x_2 \end{aligned}$$

3. 最优化的二次函数表示

只取到二次项
的泰勒展开式

二次函数

 在最优化设计中，通常经过化简，利用二次函数来表示一个复杂的函数。 n 维多元函数 $f(X)$ 二次函数描述如下：

$$f(X) = \frac{1}{2} X^T \boxed{H} X + \boxed{B^T} X + \boxed{C}$$

$n \times n$ 阶常数矩阵

n 阶常数列矩阵

常数项

4. 无约束优化问题的极值条件

无约束优化问题

 对于目标函数 $f(X)$ 求解极值，如果对变量 X 没有任何的约束限制，称为无约束优化问题。

 一元函数的无约束优化问题

 多元函数的无约束优化问题

4. 无约束优化问题的极值条件

一元函数的无约束优化问题

 通过导数计算来判断极值条件：

驻点

 必要条件：

$$f'(x^*) = 0$$

 充分条件：

$f''(x^*) > 0$  极小值点

$f''(x^*) < 0$  极大值点

$f''(x^*) = 0$  拐点

4. 无约束优化问题的极值条件

多元函数的无约束优化问题

 通过导数计算来判断极值条件：

 必要条件：

$$\nabla f(\dot{X}^*) = 0$$

$$\begin{cases} \left. \frac{\partial f(X)}{\partial x_1} \right|_{X^*} = 0 \\ \left. \frac{\partial f(X)}{\partial x_2} \right|_{X^*} = 0 \end{cases}$$

驻点

4. 无约束优化问题的极值条件

多元函数的无约束优化问题

 通过导数计算来判断极值条件：

 充分条件：

$$f(X) \approx f(X^{(k)}) + \left[\nabla f(X^{(k)}) \right]^T (X - X^{(k)}) + \frac{1}{2} \left[X - X^{(k)} \right]^T \boxed{H(X^{(k)})} (X - X^{(k)})$$

对海塞（Hessian）矩阵的“正负”进行判定

矩阵的正定、负定

 如果任意的非零向量 $X = [x_1, x_2, \dots, x_n]^T$:

 若:

$$X^T H X > 0 \quad \longrightarrow \quad H \text{正定}$$

判断条件: 各阶主子式均大于0

$$\begin{bmatrix} h_{11} & h_{12} & h_{13} & h_{14} \\ h_{21} & h_{22} & h_{23} & h_{24} \\ h_{31} & h_{32} & h_{33} & h_{34} \\ h_{41} & h_{42} & h_{43} & h_{44} \end{bmatrix} > 0, \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} > 0, \begin{bmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{bmatrix} > 0, [h_{11}] > 0$$

主子式均大于0判定

$$[h_{11}] > 0 \Rightarrow h_{11} > 0$$

$$\begin{bmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{bmatrix} > 0 \Rightarrow h_{11}h_{22} - h_{12}h_{21} > 0$$

$$\begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} > 0 \Rightarrow h_{11}h_{22}h_{33} + h_{12}h_{23}h_{31} + h_{13}h_{21}h_{32} - h_{13}h_{22}h_{31} - h_{12}h_{21}h_{33} - h_{11}h_{32}h_{23} > 0$$

矩阵的正定、负定

 如果任意的非零向量 $X = [x_1, x_2, \dots, x_n]^T$:

 若:

$$X^T H X < 0 \quad \longrightarrow \quad H \text{负定}$$

判断条件：各阶主子式负正相间（奇负偶正）

$$\begin{bmatrix} h_{11} & h_{12} & h_{13} & h_{14} \\ h_{21} & h_{22} & h_{23} & h_{24} \\ h_{31} & h_{32} & h_{33} & h_{34} \\ h_{41} & h_{42} & h_{43} & h_{44} \end{bmatrix} > 0, \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} < 0, \begin{bmatrix} h_{11} & h_{12} \\ h_{21} & h_{22} \end{bmatrix} > 0, [h_{11}] < 0$$

非正定、非负定称为不定

4. 无约束优化问题的极值条件

多元函数的无约束优化问题

 通过导数计算来判断极值条件：

 充分条件：

$$f(X) \approx f(X^{(k)}) + \left[\nabla f(X^{(k)}) \right]^T (X - X^{(k)}) + \frac{1}{2} \left[X - X^{(k)} \right]^T \boxed{H(X^{(k)})} (X - X^{(k)})$$

H 正定，极小值点
 H 负定，极大值点
 H 不定，鞍点

4. 无约束优化问题的极值条件

 例4（P20例2-5）：多元函数无约束极值求解

 求下列函数的极值点以及对应的函数值

$$f(X) = 60 - 10x_1 - 4x_2 + x_1^2 + x_2^2 - x_1x_2$$

解题思路

$$\nabla f(X) = 0 \Rightarrow X^*$$

判断 $H(X^*)$ 正定还是负定

例4：解

$$f(X) = 60 - 10x_1 - 4x_2 + x_1^2 + x_2^2 - x_1x_2$$

$$\nabla f(X) = \begin{bmatrix} -10 + 2x_1 - x_2 \\ -4 + 2x_2 - x_1 \end{bmatrix} = 0$$

$$\begin{cases} -10 + 2x_1 - x_2 = 0 \\ -4 + 2x_2 - x_1 = 0 \end{cases}$$

$$\begin{bmatrix} x_1 = 8 \\ x_2 = 6 \end{bmatrix}.$$

驻点

例4：解

$$f(X) = 60 - 10x_1 - 4x_2 + x_1^2 + x_2^2 - x_1x_2$$

$$X^* = \begin{bmatrix} 8 \\ 6 \end{bmatrix}$$

$$\begin{vmatrix} 2 & -1 \\ -1 & 2 \end{vmatrix} = 4 - 1 = 3 > 0$$


$$H(X) = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$$

$$|2| = 2 > 0$$

H正定

$$\begin{bmatrix} x_1 = 8 \\ x_2 = 6 \end{bmatrix}$$

是极小值点



$$f(8, 6) = 8$$

课后练习

 求下列函数极值点

$$f(X) = \frac{1}{3}x_1^3 + \frac{1}{3}x_2^3 - x_2^2 - x_1$$

$$f(X) = x_1^3 - x_2^3 + 3x_1^2 + 3x_2^2 - 9x_1$$